

SEMANA 6:

STEP 7 **"BÚSQUEDA DE PATRONES CON DATA MINING"**

CLASIFICACIÓN

Profesora: Stéfany Neciosup Vera
stefany.neciosup@pucp.edu.pe

9 STEPS

Fuente: Fayyad, Piatetsky-Shapiro, & Smyth (1996)




Imagen: <https://www.javatpoint.com/kdd-process-in-data-mining>

	image_name	tags
0	train_0	haze primary
1	train_1	agriculture clear primary water
2	train_2	clear primary
3	train_3	clear primary
4	train_4	agriculture clear habitation primary road





Minería
convencional



Minería
artesanal

MÉTODOS DE CLASIFICACIÓN


ANÁLISIS SUPERVISADO, PARA TARGET CATEGÓRICO



Métodos de Clasificación

<u>Tipo de clasificación</u>	<u>Característica principal</u>	<u>Ejemplo</u>	<u>Algoritmos comunes</u>
Binaria	Solo existen dos clases	Spam / No spam	Logistic Regression, SVM, Decision Tree, Random Forest, XGBoost, Naive Bayes
Multiclase (nominal)	Más de dos clases, sin orden	Clasificar dígitos (0–9)	Multinomial Logistic Regression, Decision Trees, Random Forest, SVM (OvR/OvO), Neural Nets
Ordinal	Clases con orden lógico	Nivel de satisfacción	Ordinal Logistic Regression, Ordinal SVM, Ordinal Trees, Neural Nets with ordinal loss
Multilabel	Varias clases por fila	Géneros de películas	Binary Relevance, Classifier Chains, ML-kNN, Neural Nets (sigmoid output)
Desbalanceado	Frecuencias muy distintas	Detección de fraude	Cualquier modelo + SMOTE, class weights, XGBoost, Balanced Random Forest, Focal Loss
Jerárquico	Clases con estructura de árbol	Taxonomía biológica	Hierarchical SVM, Hierarchical Trees, Neural Nets with hierarchical loss

REGRESIÓN LOGÍSTICA




- Es la extensión directa de la Regresión Lineal, al contexto de clasificación.
- Supone que **y** pertenece al conjunto de valores **{0, 1}**.
- La regresión logística usa la forma:

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}$$

- donde $p(X)$ tomará valores entre 0 y 1
- Además, tenemos la función logit o log odds:

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X$$



REGRESIÓN LOGÍSTICA MULTINOMIAL

- Para los casos en los que se tienen más de dos clases en la variable dependiente y , el modelo tiene la forma:

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}$$

- Además, la función logit toma la forma:

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$






Fig: Sigmoid Function



¿REGRESIÓN LOGÍSTICA CON ALTA DIMENSIONALIDAD?

- Tres maneras de trabajar con regresiones logisticas en escenarios de alta dimensionalidad:
 - * Pre-Selección de variables
 - * Ridge Logistic Regression
 - * Lasso Logistic Regression
- Cómo decidir cuál opción es la mejor? y cómo saber qué valores de hiperparámetros usar en cada opción?
 - * Cross Validation
 - * Validation set

REGRESIÓN LOGÍSTICA: MÉTRICA DE VALIDACIÓN



- Para clasificación sin probabilidad o score:


* Tasa de Error de Clasificación:

$$\frac{\text{\#test samples misclassified}}{\text{total \# of test samples}}$$

* Métricas basadas en ROC-curve : **AUC, Accuracy, F1**

Estas métricas deben ser calculadas en el dataset de validación que debió ser separado previamente.

REGRESIÓN LOGÍSTICA: MÉTRICA DE VALIDACIÓN




- Para clasificación probabilística, además, se tiene:

* **Suma de Errores Cuadráticos**
$$\sum_{i \in \text{test}} (y_i - \hat{p}_i)^2$$

* **Log-Likelihood predictiva**
$$-\log \left[\prod_{i \in \text{test}} \hat{p}_i^{y_i} (1 - \hat{p}_i)^{1-y_i} \right]$$


Estas métricas deben ser calculadas en el dataset de validación que debió ser separado previamente.




K-NN

K-VECINOS MÁS CERCANOS


- Modelo de clasificación no paramétrico.
- El algoritmo funciona así:
 1. Identifica las K-observaciones cuyos valores de X estén más cercanos a las observaciones sobre las cuales queremos hacer una predicción.
 2. Clasifica las observaciones de interés en la clase más frecuente entre esos K-vecinos más cercanos.






K-NN

K-VECINOS MÁS CERCANOS







K-NN

K-VECINOS MÁS CERCANOS


KNN: K=1




KNN: K=10



KNN: K=100







K-NN

K-VECINOS MÁS CERCANOS


- Es simple, intuitivo y “model-free”.
- Buena opción para pocas covariables. Con muchas covariables, los puntos de datos se dispersan tanto que un "vecino más cercano" pierde sentido.
- Tiene bajo rendimiento ante escenarios de alta dimensionalidad.







SUPPORT VECTOR MACHINES


- Pensadas para abordar escenarios de alta dimensionalidad.
- Pero no aborda la alta dimensionalidad automáticamente.
- Muy similar a la regresión logística, numéricamente.



SUPPORT VECTOR MACHINES



Azul: $\beta_0 + \beta_1 X_1 + \beta_2 X_2 > c$
Rojo: en caso contrario



Las observaciones sobre el margen
son los vectores de soporte

APLICACIÓN

ASCENSO DE
TRABAJADORES



